

Projet : Classification automatique du trafic réseau par apprentissage supervisé

Master 1 – Parcours RESI, RT, VC — Cours de Machine Learning appliqué aux réseaux

2025-07-15

1. Objectif pédagogique

Ce TP a pour objectif d'exploiter les techniques d'apprentissage supervisé pour développer un système de classification automatique du trafic réseau, en s'appuyant sur des données réelles et variées. Les étudiants devront prétraiter un jeu de données, entraîner plusieurs modèles (KNN, Arbre de décision, Random Forest, etc.), évaluer leurs performances et discuter de leur pertinence pour une utilisation en contexte réel (infrastructure réseau, opérateur télécom, sécurité...).

2. Contexte

Avec l'explosion du trafic réseau et la multiplication des usages (streaming, VoIP, cloud gaming, etc.), il devient crucial d'être capable de :

- reconnaître automatiquement le type de trafic ;
- détecter les usages anormaux ou malveillants ;
- prioriser les flux selon leur nature (VoIP, HTTP, P2P, etc.).

Dans ce TP, vous êtes amené à développer un modèle de classification supervisée, capable de différencier automatiquement plusieurs types de trafic réseau à partir de caractéristiques extraites des flux.

3. Jeu de données

Nom : TII-SSRC-23 Dataset

Source : TII-SSRC-23 on Kaggle

Description officielle

The TII-SSRC-23 dataset offers a comprehensive collection of network traffic patterns, meticulously compiled to support the development and research of Intrusion Detection Systems (IDS). It presents a dual structure: one part provides a tabular representation of extracted features in CSV format, while the other offers raw network traffic data for each type of traffic in PCAP files.

Ce TP se concentre sur la partie tabulaire du dataset (format CSV), qui contient :

- des caractéristiques statistiques extraites automatiquement de captures de paquets ;
 - des étiquettes représentant les types de trafic (VoIP, YouTube, Browsing, etc.) ;
 - un ensemble réaliste et diversifié, parfaitement adapté pour la classification supervisée.
-

4. Étapes du TP

Partie 1 – Préparation des données

1. Charger le fichier CSV fourni via Kaggle.
2. Examiner la structure (colonnes, types, valeurs manquantes).
3. Identifier la variable cible (`label`, `traffic_type`, ou `class`, selon le fichier).
4. Encoder les étiquettes (`LabelEncoder`).
5. Normaliser les colonnes numériques (`StandardScaler` ou `MinMaxScaler`).
6. Séparer les données en **X** (variables explicatives) et **y** (classe cible).

Partie 2 – Séparation des données

1. Diviser l'ensemble en deux parties :
 - Entraînement : 80 %
 - Test : 20 %
2. Vérifier l'équilibre des classes.

Partie 3 – Modélisation

Implémenter au minimum trois modèles de classification supervisée parmi les suivants :

- K-Nearest Neighbors (KNN)
- Arbre de décision (Decision Tree)
- Forêt aléatoire (Random Forest)
- Support Vector Machine (SVM)
- Régression logistique (Logistic Regression)

Pour chaque modèle :

- Entraîner le modèle sur l'ensemble d'apprentissage
- Prédire les classes sur l'ensemble de test
- Évaluer les performances :
 - Accuracy
 - Précision, Rappel, F1-score
 - Matrice de confusion
 - Temps d'entraînement (optionnel)

Partie 4 – Comparaison des modèles

1. Créer un tableau comparatif des performances.
2. Identifier le modèle le plus performant.
3. Discuter de la pertinence de chaque modèle selon les besoins (temps réel, scalabilité, etc.).
4. Visualiser les résultats à l'aide de graphiques (matrice de confusion, barres, courbes...).

Partie 5 – Analyse critique

1. Quelles classes sont bien reconnues ? Celles qui posent problème ?
 2. Quelles limitations les modèles présentent-ils (coût, surapprentissage...) ?
 3. Proposez des améliorations :
 - Réduction de dimension (PCA)
 - Sélection de variables
 - Tuning des hyperparamètres
 4. Dans quels cas d'usage concret ce système pourrait-il être déployé (FAI, entreprise, cybersécurité) ?
-

5. Livrable attendu

Un fichier Jupyter Notebook (`.ipynb`) contenant :

- Le traitement complet des données
- L'entraînement et la comparaison de plusieurs modèles
- Les résultats des évaluations
- Les réponses rédigées et justifiées aux questions d'analyse

Nom du fichier à rendre : `TP_Classification_Trafic_NomPrenom.ipynb`