

Machine Learning

Monsieur BARRO

Master 2 Resi et Telecom (ISI)

November 15, 2025

Définition l'intelligence artificielle

Machine Learning Supervis

Apprentissage Supervisé

Régression Linéaire

Régression Logistique

Algorithme des k plus proches voisins

Support Vector Machines (SVM):

Arbres de décision




Figure: l'IA

L'intelligence artificielle (IA) est un processus d'imitation de l'intelligence humaine qui repose sur la création et l'application d'algorithmes exécutés dans un environnement informatique dynamique.

Son but est de permettre à des ordinateurs de penser et d'agir comme des êtres humains.

Pour y parvenir, trois composants sont nécessaires :

- ▶ Des systèmes informatiques
- ▶ Des données avec des systèmes de gestion
- ▶ Des algorithmes d'IA avancés (code)

Pour se rapprocher le plus possible du comportement humain, l'intelligence artificielle a besoin d'une quantité de données et d'une capacité de traitement élevées.

- ▶ Aujourd'hui, les progrès techniques de l'IA concernent en effet principalement le domaine du machine learning, c'est-à-dire l'ensemble des algorithmes qui permettent d'apprendre en identifiant des relations entre des données et de produire des modèles prédictifs de manière autonome.
- ▶ Le deep learning, ou apprentissage profond, est un domaine particulier du machine learning dont les algorithmes sont particulièrement efficaces dans le traitement des données complexes et non structurées comme les images ou la voix.

Le Machine Learning peut être défini comme étant une technologie d'intelligence artificielle permettant aux machines d'apprendre sans avoir été préalablement programmées spécifiquement à cet effet.

Le Machine Learning est explicitement lié au Big Data, étant donné que pour apprendre et se développer, les ordinateurs ont besoin de flux de données à analyser, sur lesquels s'entraîner. De ce fait, le Machine Learning, issu par essence du Big Data, a précisément besoin de ce dernier pour fonctionner. Le Machine Learning et le Big Data sont donc interdépendants.

Le Machine Learning est un sous-ensemble de l'intelligence artificielle (IA).

Cette technologie vise à apprendre aux machines à tirer des enseignements des données et à s'améliorer avec l'expérience, au lieu d'être explicitement programmés à le faire.

Dans le Machine Learning, les algorithmes sont entraînés à trouver des patterns et des corrélations dans de grands ensembles de données, ainsi qu'à prendre les meilleures décisions et à émettre les meilleures prévisions en s'appuyant sur leur analyse.

Avec la pratique, les applications du Machine Learning s'améliorent

Apprentissage Supervisé

La majorité des apprentissages automatiques utilisent un apprentissage supervisé (supervised learning). L'apprentissage supervisé consiste en des variables d'entrée (x) et une variable de sortie (Y). Vous utilisez un algorithme pour apprendre la fonction de mapping de l'entrée à la sortie.

$$f(x) = y$$

Le but est d'appréhender si bien la fonction de mapping que, lorsque vous avez de nouvelles données d'entrée (x), vous pouvez prédire les variables de sortie (Y) pour ces données. C'est ce qu'on appelle l'apprentissage supervisé, car le processus d'un algorithme tiré de l'ensemble de données de formation (training set) peut être considéré comme un enseignant supervisant le processus d'apprentissage.

Nous connaissons les réponses correctes, l'algorithme effectue des prédictions itératives sur les données d'apprentissage et est corrigé par l'enseignant.

L'apprentissage s'arrête lorsque l'algorithme atteint un niveau de performance acceptable.

C'est ce qu'on appelle l'apprentissage supervisé, car le processus d'un algorithme tiré de l'ensemble de données de formation (training set) peut être considéré comme un enseignant supervisant le processus d'apprentissage.

Nous connaissons les réponses correctes, l'algorithme effectue des prédictions itératives sur les données d'apprentissage et est corrigé par l'enseignant.

L'apprentissage s'arrête lorsque l'algorithme atteint un niveau de performance acceptable.




FIGURE 1.1 – Apprentissage supervisé.

Figure: Apprentissage Supervisé

Classification binaire est Un problème d'apprentissage supervisé dans lequel l'espace des étiquettes est binaire, autrement dit $Y = 0, 1$ est appelé un problème de classification binaire.

Classification multi-classe) Un problème d'apprentissage supervisé dans lequel l'espace des étiquettes est discret et fini, autrement dit $Y = 1, 2, \dots, C$ est appelé un problème de classification multi-classe. C est le nombre de classes.

Régression Linéaire

L'algorithme de régression linéaire est un algorithme d'apprentissage supervisé c'est-à-dire qu'à partir de la variable cible ou de la variable à expliquer (Y), le modèle a pour but de faire une prédiction grâce à des variables dites explicatives (X) ou prédictives.

Un modèle de régression linéaire est un modèle de machine learning dont la variable cible (Y) est quantitative tandis que la variable X peut être quantitative ou qualitative.

L'objectif est de trouver une fonction dite de prédiction ou une fonction coût qui décrit la relation entre X et Y. La fonction recherchée est de la forme :

$$Y = f(X)$$

avec $f(X)$ une fonction linéaire

Nous choisissons une fonction de décision f de la forme:

$$f : x \rightarrow \beta_0 + \sum_j^p \beta_j x_j$$

Ici, $\beta \in \mathbb{R}^{p+1}$ et donc $m = p + 1$.

On appelle régression linéaire le modèle de la forme

$f : x \rightarrow \beta_0 + \sum_{j=1}^p \beta_j x_j$ dont les coefficients sont obtenus par minimisation de la somme des moindres carrés, à savoir :

$$\arg \min_{\beta \in \mathbb{R}^{p+1}} \left(\sum_{i=1}^n (y_i - (\beta_0 + \sum_i^p \beta_i x_i))^2 \right)$$

La régression linéaire produit un modèle interprétable, au sens où les β_j permettent de comprendre l'importance relative des variables sur la prédiction. En effet, plus $|\beta_j|$ est grande, plus la j -ème variable a un effet important sur la prédiction, et le signe de β_j nous indique la direction de cet effet.

Régression Logistique

La régression logistique est un modèle statistique permettant d'étudier les relations entre un ensemble de variables qualitatives X_i et une variable qualitative Y .

Il s'agit d'un modèle linéaire généralisé utilisant une fonction logistique comme fonction de lien.

Un modèle de régression logistique permet aussi de prédire la probabilité qu'un événement arrive (valeur de 1) ou non (valeur de 0) à partir de l'optimisation des coefficients de régression. Ce résultat varie toujours entre 0 et 1.

Lorsque la valeur prédite est supérieure à un seuil, l'événement est susceptible de se produire, alors que lorsque cette valeur est inférieure au même seuil, il ne l'est pas

Contexte

Y est une variable binaire

0 en cas de non occurrence de l'évènement.

1 si occurrence.

X aléatoire et X_i non aléatoires

On cherche à expliquer la survenue d'un évènement

On cherche la probabilité de succès

On travaille en terme d'espérance

Ainsi, nous cherchons donc à modéliser $\log P(Y = 1|x)$
 $1P(Y = 1|x)$ comme la combinaison linéaire $\beta > x$, où, de
manière équivalente, $P(Y = 1|x)$ comme $\sigma(\beta > x)$. Nous
utilisons ici la transformation de x .

Cas d'une seule variable exogène binaire

- Odds ratio (ou « rapport des cotes ») C'est le rapport des cotes des probabilités d'avoir la maladie pour ceux qui ont un symptôme X d'une part et de ceux qui ne l'ont pas d'autre part.
- $OR=1$, la maladie est indépendante du symptôme
- $OR>1$, la maladie est plus fréquente pour les individus qui ont le symptôme.
- $OR<1$, la maladie est plus fréquente pour les individus qui n'ont pas le symptôme.

Cas d'une seule variable exogène quantitative

- X une variable quantitative (ex: âge)
- Y=0: la maladie est absente
- Y=1: la maladie est présente
- On a encore: II. Interprétation des coefficients

$$\text{logit}[P(Y_i = 1|X = x)] = \beta_0 + \beta x$$


Cas d'une Modèle logistique multiple

- L'interprétation est semblable à celle des modèles à une variable explicative.
- Exemple:

$$\text{logit}[P(\text{maladie} = 1 | \text{Age}, \text{Fume})] = \beta_0 + \beta_1 \text{Age} + \beta_1 \text{Fume}$$


Algorithme des k plus proches voisins :

L'algorithme des k plus proches voisins, souvent appelé k NN d'après son nom anglais k Nearest Neighbors, est un algorithme d'apprentissage automatique supervisé. Son fonctionnement peut être assimilé à l'analogie suivante « dis-moi qui sont tes voisins, je te dirais qui tu es ».



Alligators

Crocodiles



Activator V

Principe de l'algorithme:

On suppose que l'ensemble E contiennent n données labellisées et u , une autre donnée n'appartenant pas à E qui ne possède pas de label. Soit d une fonction qui renvoie la distance (qui reste à choisir) entre la donnée u et une donnée quelconque appartenant à E .

Soit un entier k inférieur ou égal à n . Le principe de l'algorithme de k -plus proches voisins est le suivant:

- On calcule les distances entre la donnée u et chaque donnée appartenant à E à l'aide de la fonction d .
- On retient les k données du jeu de données E les plus proches de u .
- On attribue à u la classe qui est la plus fréquente parmi les k données les plus proches.

Pour appliquer ce principe, il faudra :

- Évaluer la distance qui sépare le nouvel élément de chacun des autres points de l'ensemble E. Chaque point de l'ensemble est caractérisé par son indice i .
- Stocker ces valeurs de distance d dans une liste du type : $[[d,i],[\dots],\dots]$, où d est la distance qui sépare le nouvel élément du point d'indice i .
- Trier la liste selon les valeurs des distances d .
- Choisir les k premiers points de la liste triée qui sont donc les k -plus proches voisins.
- Assigner une classe au nouvel élément en fonction de la majorité des classes représentées parmi les k plus proches voisins.


On aura donc besoin de trois fonctions :

- une fonction distance pour calculer la distance entre deux points de coordonnées connues.
- Une fonctions kvoisins qui détermine les kplus proches voisins d'un nouvel élément.
- Une fonction predire_classe qui détermine le résultat majoritaire des classes d'appartenance des kplus proches voisins et assigne la classe du nouvel élément à cette classe majoritaire.

Support Vector Machines (SVM): Définition

SVM (Support Vector Machine ou Machine à vecteurs de support) est un algorithme d'apprentissage automatique supervisé qui peut être utilisé pour les problèmes de classification ou de régression. Toutefois, il est surtout utilisé dans les problèmes de classification.

Support Vector Machines (SVM):



Fonctionnement de l'algorithme SVM


Le principe des SVM consiste à ramener un problème de classification ou de discrimination à un hyperplan (feature space) dans lequel les données sont séparées en plusieurs classes dont la frontière est la plus éloignée possible des points de données (ou marge maximale).

Example

On dispose d'une population composée de 50% de femme et 50% d'hommes. En utilisant un échantillon de cette population, on veut créer un ensemble de règles qui nous guideront dans la classification de sexe pour le reste de la population.

On suppose que les deux facteurs de différenciation identifiés sont : la taille de l'individu et la longueur des cheveux. Voici un diagramme de dispersion de l'échantillon:

Support Vector Machines (SVM):



Support Vector Machines (SVM):

Les cercles bleus dans le graphique représentent les femmes et les carrés verts représentent les hommes. Visuellement, on peut distinguer ces deux classes comme suit :

Les hommes de cette population ont une taille moyenne plus élevée.

Les femmes de cette population ont des cheveux plus longs. Supposons qu'on a un individu avec la hauteur 180 cm et la longueur des cheveux 4 cm qu'on devra classer. Intuitivement, on va le placer avec les hommes.

Support Vector Machines (SVM):


Comment peut-on amener la machine à comprendre ce type de principes et l'appliquer sur de nouveaux éléments n'appartenant pas à la population de base?

À l'aide d'un classificateur de la famille SVM cela est possible à travers un hyperplan séparateur bien choisi.

On commence tout d'abord par projeter chaque élément de données dans l'espace ndimensionnel (où n représente le nombre de caractéristiques présents dans le jeu de données) avec la valeur de chaque caractéristique étant la valeur d'une coordonnée particulière.

Ensuite, on effectue la classification en trouvant l'hyperplan qui différencie très bien les deux classes. Dans le cas de la population ci-dessus, plusieurs choix se présentent.

Support Vector Machines (SVM):



Arbres de décision :

L'apprentissage par arbre de décision est une méthode classique en apprentissage automatique. Son but est de créer un modèle qui prédit la valeur d'une variable-cible depuis la valeur de plusieurs variables d'entrée.

Les arbres de classification et de régression (parfois aussi appelés arbres de segmentation ou de décision) sont des méthodes qui permettent d'obtenir des modèles à la fois explicatifs et prédictifs.

Parmi leurs avantages on notera d'une part leur simplicité du fait de la visualisation sous forme d'arbres, d'autre part la possibilité d'obtenir des règles en langage naturel.

On distingue notamment deux cas d'utilisation de ces modèles :

- ▶ On utilise les arbres de classification pour expliquer et/ou prédire l'appartenance d'objets (observations, individus) à une classe (ou modalité ou catégorie) d'une variable qualitative, sur la base de variables explicatives quantitatives et/ou qualitatives.
- ▶ On utilise les arbres de régression pour expliquer et/ou prédire les valeurs prises par une variable dépendante quantitative, en fonction de variables explicatives quantitatives et/ou qualitatives